Языковые модели

Машинное обучение в диалоговых системах
Лекция 7
26 марта 2019

Суть

План на сегодня

- Авторегрессионные модели
- Способы оценивания и перплексия
- LM на n-граммах
- LM на рекуррентных сетях
- Генерация текстов
- Shallow / deep fusion
- Transfer / multi-task learning
- Всякие трюки для ускорения обучения

Марковские цепи

Це́пь Ма́ркова — последовательность случайных событий с конечным или счётным числом исходов, характеризующаяся тем свойством, что, говоря нестрого, при фиксированном настоящем будущее независимо от прошлого. Названа в честь А. А. Маркова (старшего).

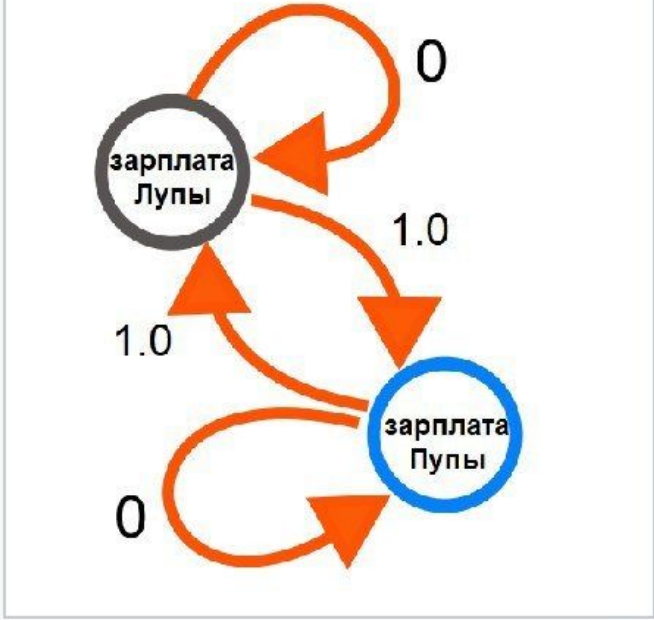

Пример цепи с двумя состояниями

Языковые модели

- Язык тоже можно описать марковскими цепями
- Состояние — префикс текста
- Переход — выбор следующего слова

N-граммы

- Не обязательно все делать нейросетями
- Не обязательно вообще как-либо использовать ML

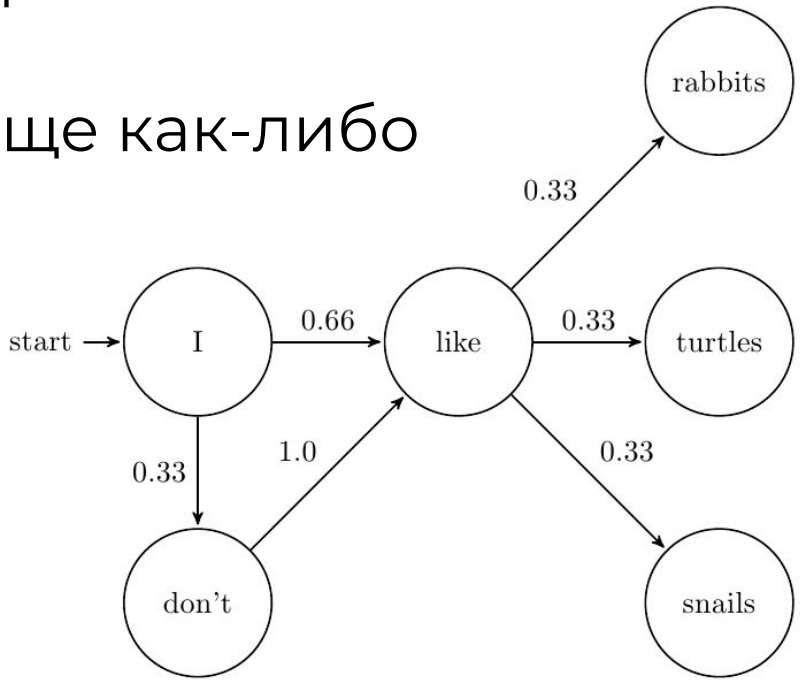

Биграммы: обучение

```
class TextGenerator:
    '''Primitive bigram statistics based model.'''
    def __init__(self, data, lc):
        '''If given a list, porcesses multiple files.
        Otherwise, processes just one string.'''
        self.lc = lc
        self.bigrams = {}
        if isinstance(data, str):
            self.add(data)
        else:
            assert isinstance(data, list)
            for path in data:
                with open(path) as file:
                    for line in file:
                        self.add(line)

    def add(self, line):
        '''Trains on single line.'''
        words = re.findall(r'\p{L}+', line)
        if self.lc:
            words = list(map(str.lower, words))
        for prev_word, next_word in zip(words, words[1:]):
            self.bigrams.setdefault(prev_word, {})
            self.bigrams[prev_word].setdefault(next_word, 0)
            self.bigrams[prev_word][next_word] += 1
```

Биграммы: генерация

```
def generate(self, length, state=None):
    assert len(self.bigrams) > 0
    sentence = []
    for _ in range(length):
        if state not in self.bigrams:
            state = choice(list(self.bigrams.keys()))
        sentence += [state]
        d = self.bigrams[state]
        words = list(d.keys())
        counts = list(d.values())
        total = sum(counts)
        probs = [x / total for x in counts]
        state = choice(words, p=probs)
    assert len(sentence) == length
    return sentence
```

N-граммы

- Быстрое обучение: нужно просто один раз пройтись по тексту
- Быстрый inference: просто сэмплирование
- Не умеют улавливать долгосрочные зависимости
- Много весят (порядка исходного текста)
- Нельзя встроить в вычислительный граф

Нейросети

- Закодируем сеткой префикс, применим к выходу softmax и будем предсказывать следующее слово
- Логично применить какую-нибудь рекуррентную сеть (LSTM, GRU)

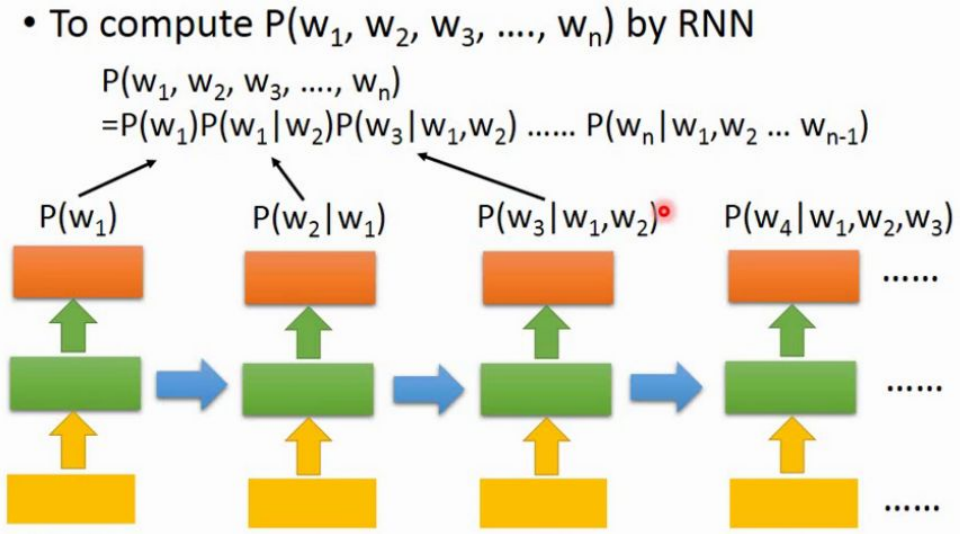

Нейросети: генерация

1. Поддерживаем hidden state рекуррентной сети
2. Делаем из него вероятностное распределение (linear + softmax)
3. Сэмплируем слово из этого распределения
4. Выписываем это слово, кормим **его же** эмбеддинг на вход ячейке RNN, обновляем hidden
5. Если не пришли в терминальное состояние (сгенерировали точку), goto 1

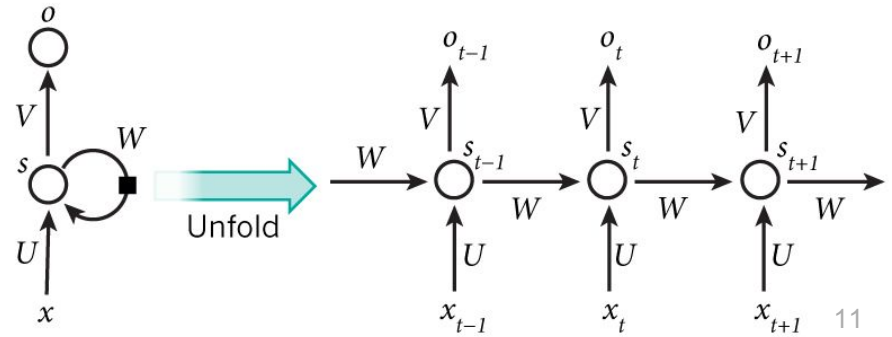

Как их оценивать

- $P(w_n, w_{n-1}, w_{n-2}, \ldots, w_1) = \prod_{i=1}^{n} P(w_i | w_{i-1}, w_{i-2}, \ldots, w_1)$
- Учимся предсказывать $P(w_i | w_{i-1}, w_{i-2}, \ldots, w_1)$
- **Перплексия** $PP = \hat{P}(w_1, w_2, \ldots, w_m)^{-\frac{1}{m}}$
- Чем меньше — тем лучше
- Выход модели — вероятностное распределение
- По сути, мы делаем классификацию — логично использовать кроссэнтропию как функцию потерь

Teacher forcing

- Применим лосс не только к последнему выходу, а сразу ко всем
- ⇔ предсказываем собственный вход, смещенный на единицу
- Маски: после конца предложения ничего делать не надо

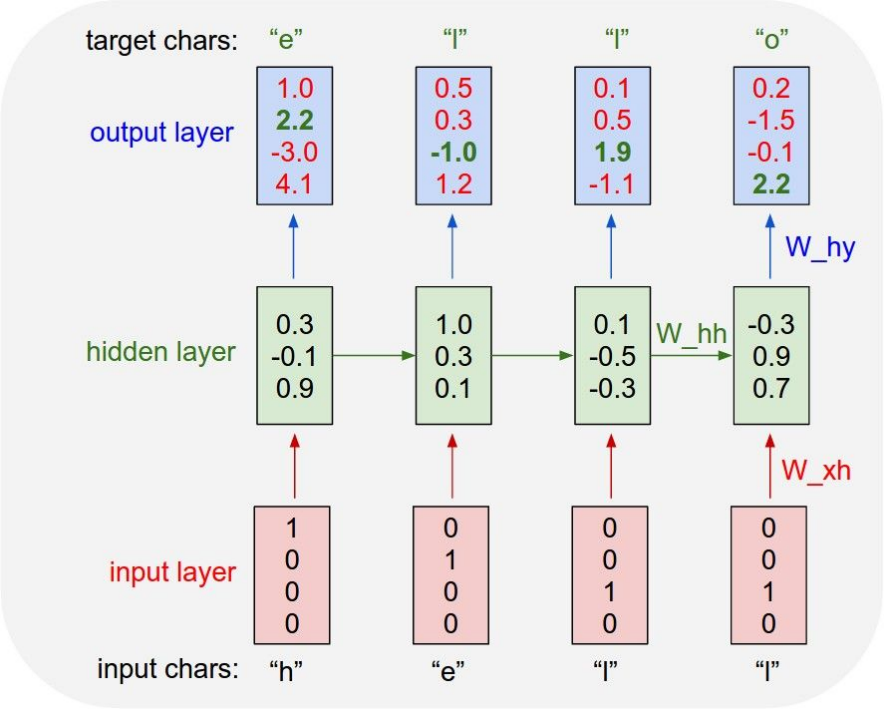

Checkpoint

- Очень важно осознать всё, что было до этого слайда
- Семинар / домашка — реализовать языковую модель
- Задавайте вопросы, если вам что-либо не до конца ясно

Ок, зачем это надо?

- Проверка орфографии
- Подсказки в поиске
- Генерация текстов
- Генеративный чат-бот
- Распознавание речи
- Машинный перевод
- Тренд 2018 года: transfer learning в NLP
- Весь мир сейчас учится делать из LM-ок что-нибудь полезное

Генерация текстов: Шейкспир

PANDARUS:
Alas, I think he shall be come approached and the day
When little srain would be attain'd into being never fed,
And who is but a chain and subjects of his death,
I should not sleep.

Second Senator:
They are away this miseries, produced upon my soul,
Breaking and strongly should be buried, when I perish
The earth and thoughts of many states.

DUKE VINCENTIO:
Well, your wit is in the care of side and that.

Second Lord:
They would be ruled after this chamber, and
my fair nues begun out of the fact, to be conveyed,
Whose noble souls I'll have the heart of the wars.

Clown:
Come, sir, I will make did behold your worship.

Генерация текстов: ядро Linux

```
/*
 * Increment the size file of the new incorrect UI_FILTER group information
 * of the size generatively.
 */
static int indicate_policy(void)
{
  int error;
  if (fd == MARN_EPT) {
    /*
     * The kernel blank will coeld it to userspace.
     */
    if (ss->segment < mem_total)
      unblock_graph_and_set_blocked();
    else
      ret = 1;
    goto bail;
  }
  segaddr = in_SB(in.addr);
  selector = seg / 16;
  setup_works = true;
  for (i = 0; i < blocks; i++) {
    seq = buf[i++];
    bpf = bd->bd.next + i * search;
    if (fd) {
      current = blocked;
    }
  }
  rw->name = "Getjbbregs";
  bprm_self_clearl(&iv->version);
  regs->new = blocks[(BPF_STATS << info->historidac)] | PFMR_CLOBATHINC_SECONDS << 12;
  return segtable;
}
```

Генерация текстов: arxiv

For $\bigoplus_{n=1,\ldots,m}$ where $\mathcal{L}_{m_\bullet} = 0$, hence we can find a closed subset $\mathcal{H}$ in $\mathcal{H}$ and any sets $\mathcal{F}$ on X, U is a closed immersion of S, then $U \to T$ is a separated algebraic space.

Proof. Proof of (1). It also start we get

$$S = \mathrm{Spec}(R) = U \times_X U \times_X U$$

and the compariconly in the fibre product covering we have to prove the lemma generated by $\coprod Z \times_U U \to V$. Consider the maps M along the set of points Sch_{fppf} and $U \to U$ is the fibre category of S in U in Section, ?? and the fact that any U affine, see Morphisms, Lemma ??. Hence we obtain a scheme S and any open subset $W \subset U$ in $Sh(G)$ such that $\mathrm{Spec}(R') \to S$ is smooth or an

$$U = \bigcup U_i \times_{S_i} U_i$$

which has a nonzero morphism we may assume that f_i is of finite presentation over S. We claim that $\mathcal{O}_{X,x}$ is a scheme where $x, x', s'' \in S'$ such that $\mathcal{O}_{X,x'} \to \mathcal{O}'_{X',x'}$ is separated. By Algebra, Lemma ?? we can define a map of complexes $\mathrm{GL}_{S'}(x'/S'')$ and we win. □

To prove study we see that $\mathcal{F}|_U$ is a covering of $\mathcal{X}'$, and $\mathcal{T}_i$ is an object of $\mathcal{F}_{X/S}$ for $i > 0$ and $\mathcal{F}_p$ exists and let $\mathcal{F}_i$ be a presheaf of $\mathcal{O}_X$-modules on $\mathcal{C}$ as a $\mathcal{F}$-module. In particular $\mathcal{F} = U/\mathcal{F}$ we have to show that

$$\widetilde{M}^\bullet = \mathcal{I}^\bullet \otimes_{\mathrm{Spec}(k)} \mathcal{O}_{S,s} - i_X^{-1}\mathcal{F})$$

is a unique morphism of algebraic stacks. Note that

$$\mathrm{Arrows} = (Sch/S)^{opp}_{fppf}, (Sch/S)_{fppf}$$

and

$$V = \Gamma(S, \mathcal{O}) \longmapsto (U, \mathrm{Spec}(A))$$

is an open subset of X. Thus U is affine. This is a continuous map of X is the inverse, the groupoid scheme S.

Proof. See discussion of sheaves of sets. □

The result for prove any open covering follows from the less of Example ??. It may replace S by $X_{spaces,étale}$ which gives an open subspace of X and T equal to S_{Zar}, see Descent, Lemma ??. Namely, by Lemma ?? we see that R is geometrically regular over S.

Lemma 0.1. *Assume (3) and (3) by the construction in the description.*

Suppose $X = \lim |X|$ *(by the formal open covering* X *and a single map* $\underline{Proj}_X(\mathcal{A}) =$ $\mathrm{Spec}(B)$ *over* U *compatible with the complex*

$$Set(\mathcal{A}) = \Gamma(X, \mathcal{O}_{X,\mathcal{O}_X}).$$

When in this case of to show that $\mathcal{Q} \to \mathcal{C}_{Z/X}$ *is stable under the following result in the second conditions of (1), and (3). This finishes the proof. By Definition ?? (without element is when the closed subschemes are catenary. If* T *is surjective we may assume that* T *is connected with residue fields of* S*. Moreover there exists a closed subspace* $Z \subset X$ *of* X *where* U *in* X' *is proper (some defining as a closed subset of the uniqueness it suffices to check the fact that the following theorem*

(1) f *is locally of finite type. Since* $S = \mathrm{Spec}(R)$ *and* $Y = \mathrm{Spec}(R)$.

Proof. This is form all sheaves of sheaves on X. But given a scheme U and a surjective étale morphism $U \to X$. Let $U \cap U = \coprod_{i=1,\ldots,n} U_i$ be the scheme X over S at the schemes $X_i \to X$ and $U = \lim_i X_i$. □

The following lemma surjective restrocomposes of this implies that $\mathcal{F}_{x_0} = \mathcal{F}_{x_0} = \mathcal{F}_{\mathcal{X},\ldots,0}$.

Lemma 0.2. *Let* X *be a locally Noetherian scheme over* S, $E = \mathcal{F}_{X/S}$. *Set* $\mathcal{I} = \mathcal{J}_1 \subset \mathcal{I}'_n$. *Since* $\mathcal{I}^n \subset \mathcal{I}^n$ *are nonzero over* $i_0 \leq \mathfrak{p}$ *is a subset of* $\mathcal{J}_{n,0} \circ \overline{A}_2$ *works.*

Lemma 0.3. *In Situation* ??. *Hence we may assume* $\mathfrak{q}' = 0$.

Proof. We will use the property we see that $\mathfrak{p}$ is the mext functor (??). On the other hand, by Lemma ?? we see that

$$D(\mathcal{O}_{X'}) = \mathcal{O}_X(D)$$

where K is an F-algebra where δ_{n+1} is a scheme over S. □

Генерация музыки

Seq2seq

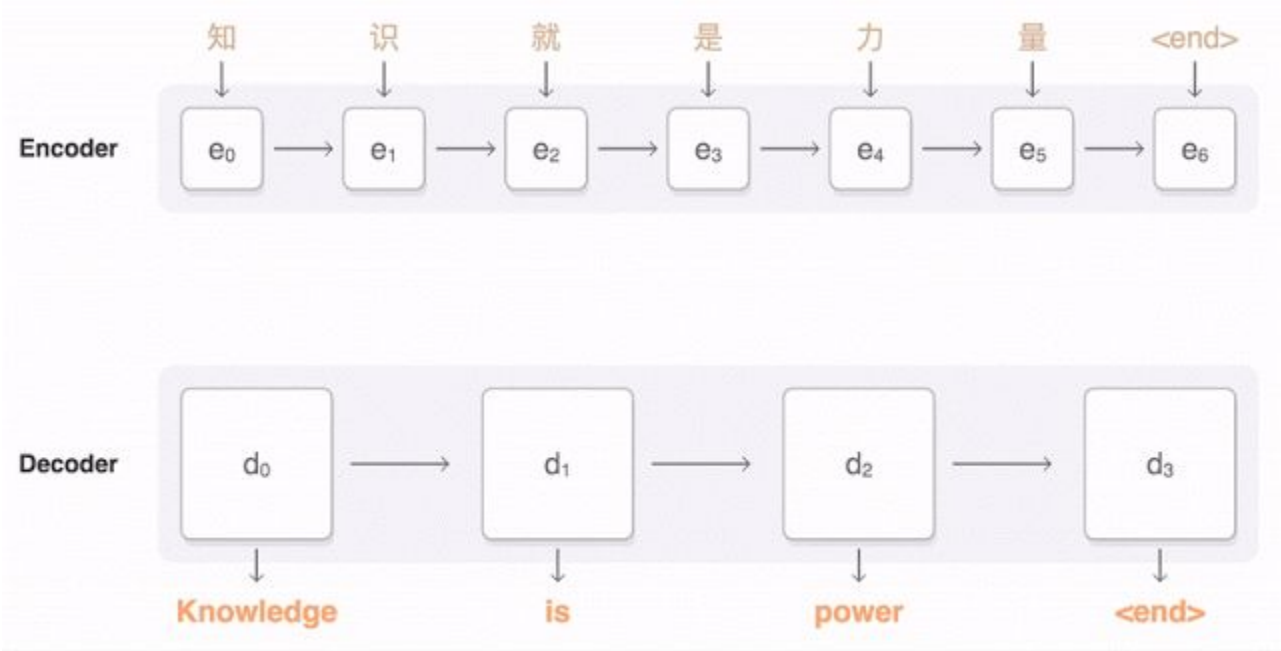
知
识
就
是
力
量
<end>
Encoder
e0
e1
e2
e3
e4
e5
e6
Decoder
d0
d1
d2
d3
Knowledge
is
power
<end>

Где нужно генерировать текст

- Распознавание речи
- Переводчик
- Image captioning
- Чат-бот
- Подсказки в поиске
- Style transfer для текстов

Beam Search

- В seq2seq-задачах нам нужно сгенерировать самый вероятный ответ, а не просто из распределения
- Перебирать все возможные ответы и скорить — долго
- Каждое следующее слово брать как самое вероятное — не всегда оптимально

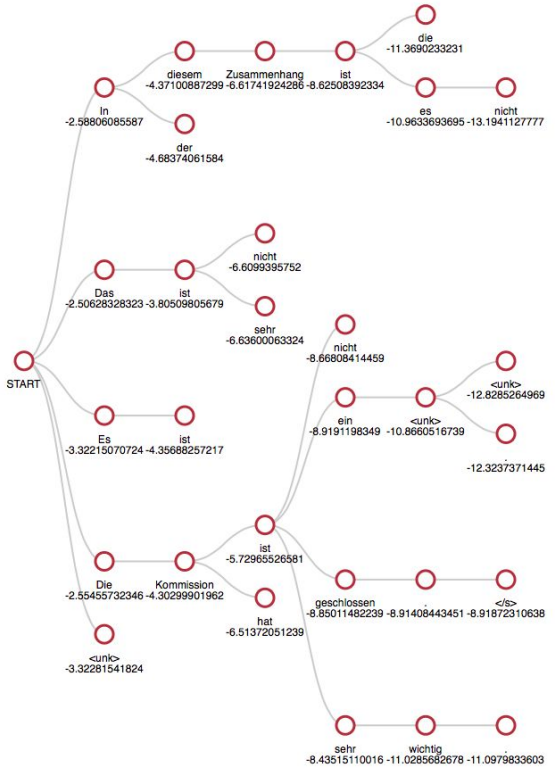

Beam Search

- Будем поддерживать K самых вероятных кандидатов
- Из каждого сгенерируем N кандидатов-продолжений
- Выберем их этих KN кандидатов K самых вероятных
- После EOS ничего генерировать не надо

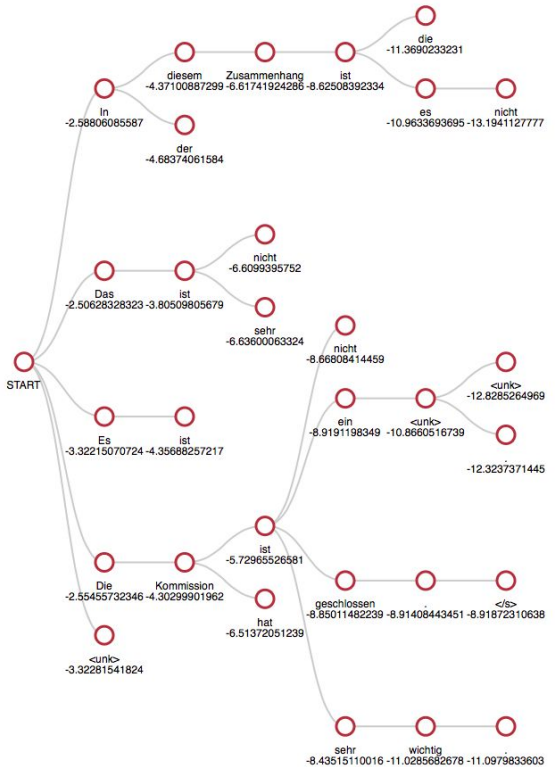

Сжатие данных

- Hutter Prize — чемпионат мира по сжатию англоязычной Википедии
- Есть способ сделать из языковой модели кодировщик: арифметическое кодирование
- Впрочем, конкретно на Hutter Prize побеждают не нейросети — учитывается длина всей программы, а параметры нейронки сами весят больше википедии

Ансамблирование

- Моделирование естественного языка — «AI-полная» задача
- Данных для обучения **очень** много
- Обученная языковая модель хранит в себе огромную информацию о языке
- Высоковероятный по мнению LM вывод скорее всего правильный
- Её мнение можно учитывать при решении seq2eq-задач, где данных не бесконечность

Deep и shallow fusion

- Shallow fusion: языковая модель используется только во время inference (обычное ансамблирование)
- Deep fusion: в логиты основной модели с каким-то коэффициентом прибавляются логиты LM-ки, все обучается как одна цельная сеть

Sentiment Neuron (OpenAI, 2017)

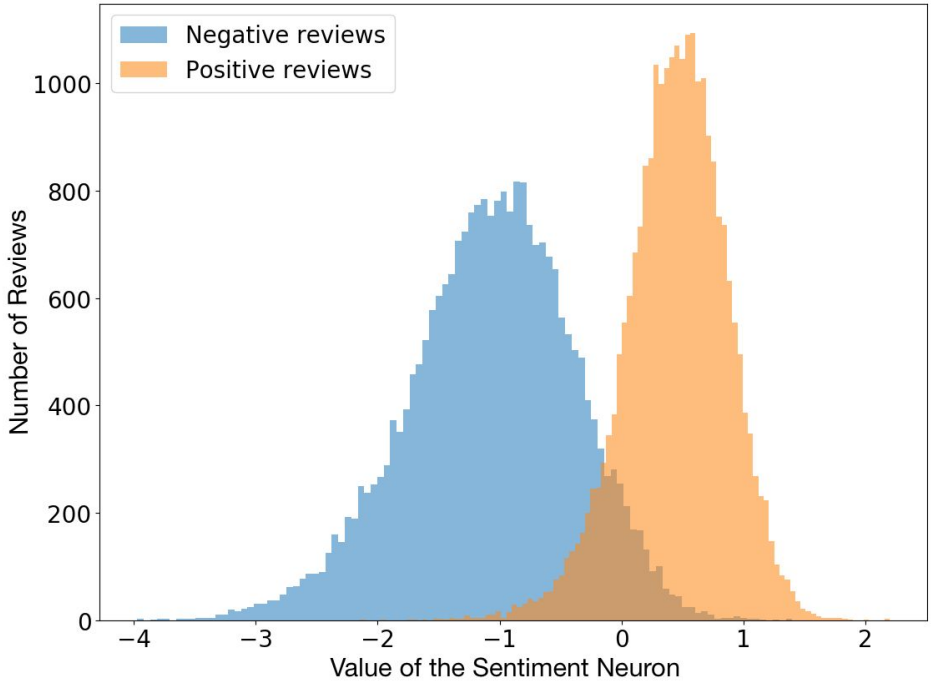

Sentiment Neuron

This is one of Crichton's best books. The characters of Karen Ross, Peter Elli
Munro, and Amy are beautifully developed and their interactions are exciti
complex, and fast-paced throughout this impressive novel. And about 99.8 percent
that got lost in the film. Seriously, the screenplay AND the directing w
horrendous and clearly done by people who could not fathom what was good about
novel. I can't fault the actors because frankly, they never had a chance to make t
turkey live up to Crichton's original work. I know good novels, especially those w
a science fiction edge, are hard to bring to the screen in a way that lives up to
original. But this may be the absolute worst disparity in quality between novel

Обучать state-of-the-art LM сложно

- Очень много данных
- Capacity модели почти не ограничена
- Даже если данных бесконечность, о регуляризации все равно нужно беспокоиться (в AWD-LSTM три разных дропаута)
- Очень много весов из-за необходимости делать логистическую регрессию на много слоев, их все нужно считать

Hierarchical softmax (Facebook, 2017)

- Мысленно разделим выход softmax-а на две части
- Добавим вершину, в которой будет решаться, в какую половину пойти
- Каждую половину тоже рекурсивно разделим
- Дерево должно минимизировать ожидаемую глубину токена
- Знаете такое?

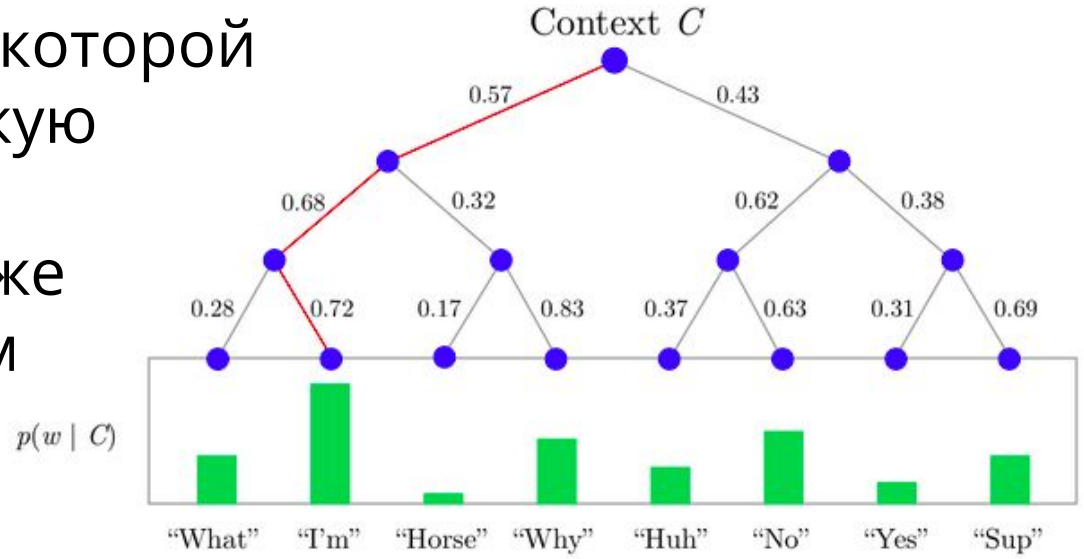

Дерево Хаффмана

- Тоже пришло из теории информации и сжатии данных
- Минимизирует ожидаемую глубину токена

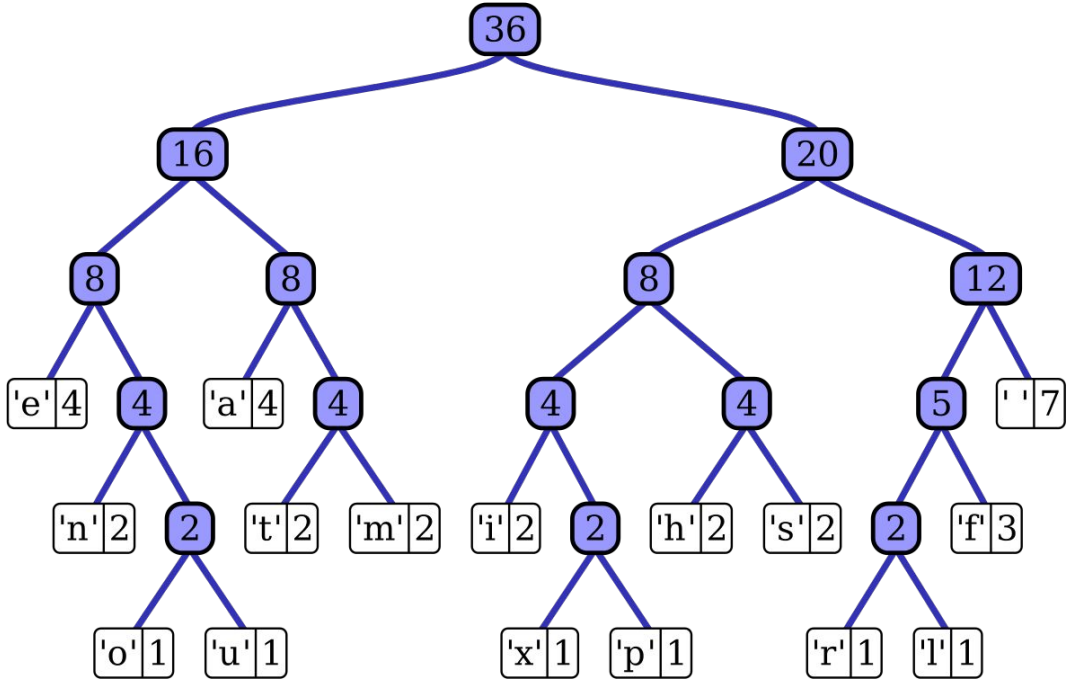

Hierarchical softmax

- Получается аппроксимация обычного софтмакса
- Качество чуть хуже, но зато работает за O(log n)
- В обычных языковых моделях никто особо не использует,
  но идея прикольная

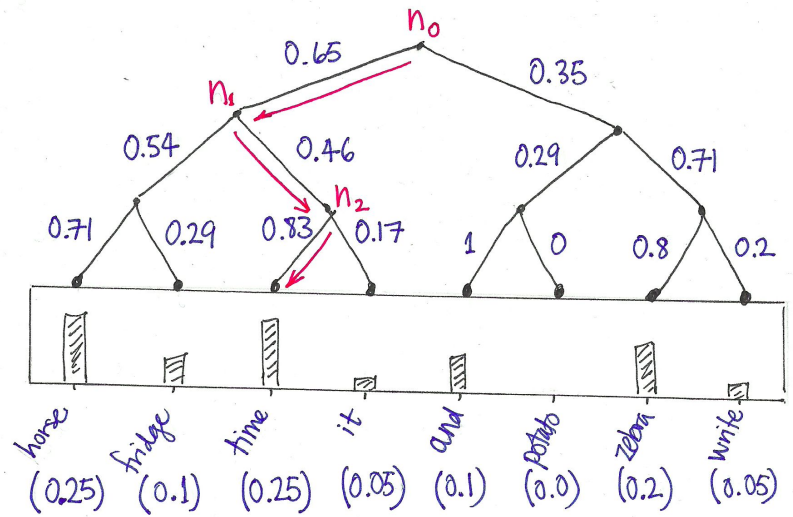

$P(\cdot|c)$

Weight sharing

- По сути, в конце LM стоит логистическая регрессия на кучу классов
- Большинство весов в LM
  — эмбеддинги и эта логрегрессия
- Классов столько же, сколько и разных токенов
- Эти веса примерно об одном и том же
- Давайте объединим веса эмбеддингов и коэффициенты регрессии
- Параметров стало в ~2 раза меньше

Breaking the softmax bottleneck (CMU, 2018)

- tl;dr: давайте подумаем, что происходит, когда мы из hidden получаем логиты
- Hidden-ов очень много, зависимость между ними и распределением следующих токенов одна логрегрессия не уловит
- Давайте просто сделаем несколько логрегрессий, а предсказания как-нибудь усредним (Mixture of Softmaxes)
- Клёво, скор действительно улучшается
- В теории работает, но...

Как работает распределенное обучение

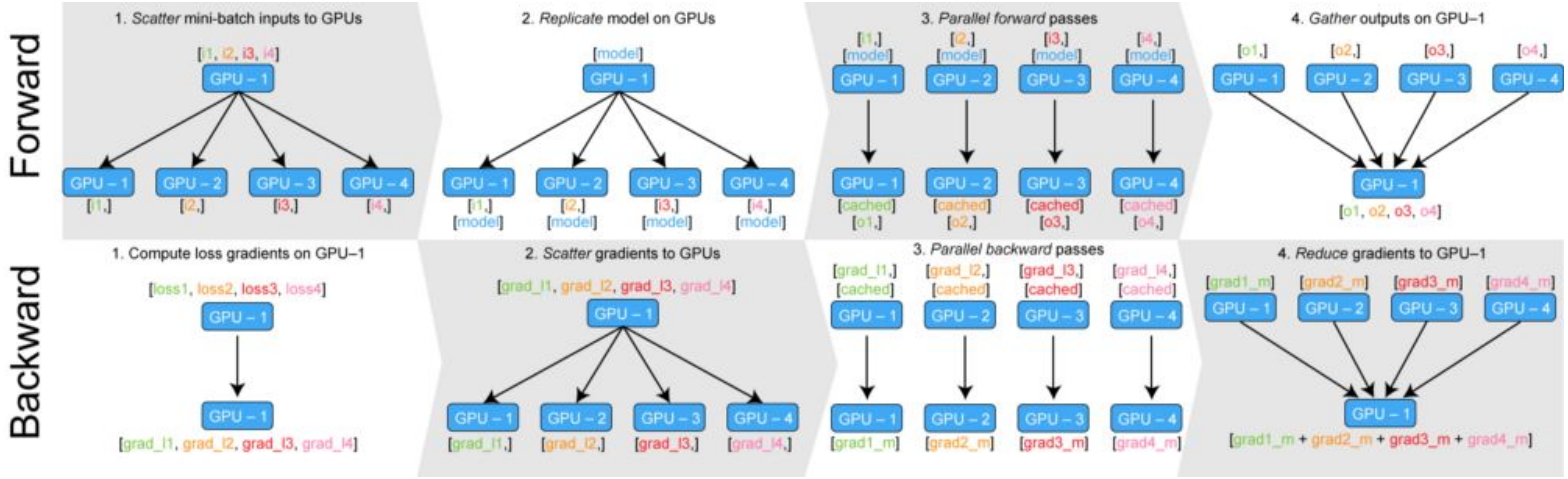

Память при обучении

- Размер словаря = 40k
- Длины предложений = 250
- Размер батча = 32
- Таких штук нужно две (градиенты тоже)
- Берем в руки калькулятор,
  получаем 2.4гб на один только softmax
- В обычых GPU около 10гб
- **Это всё надо как минимум передавать по сети**

Google хотят обучить LM на 1B параметров

Byte-pair-encoding (U of Edinburgh, 2016)

- Возьмем текст, посмотрим на все пары соседних символов
- Заменим самую частую пару на новый символ
- Goto 1, пока не заполнили vocab size
- Подходит странных языков со сложной морфологией, типа нашего
- Заходит в машинном переводе — универсальная токенизация для любого языка

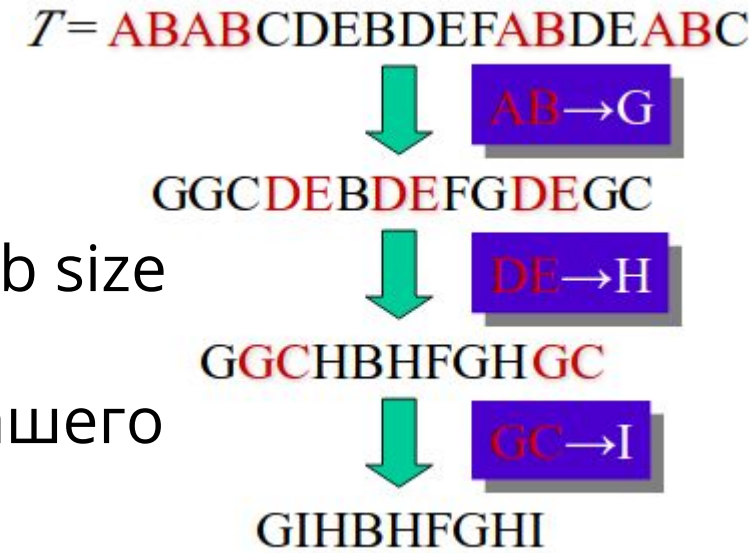

Звучит как какая-то дешевая эвристика
github.com/google/sentencepiece

tl;dr: давайте сделаем слишком много BPE, а потом будем выкидывать самые бесполезные токены (по мнению юниграммной языковой модели)

Текущий state-of-the-art:
openai.com/blog/better-language-models/

Практическая часть